

Inteligência Computacional

The background of the slide features a close-up, slightly blurred image of a computer monitor. The monitor's bezel is visible on the right side. The screen displays text in a serif font. The word 'monitor' is prominent in a bold, lowercase font. Above it, the word 'ORIGIN' is visible in a smaller, uppercase font. Below 'monitor', there are several lines of text, including 'thing 2', 'duties 3', and 'picture'. The overall color scheme is a cool blue.

Diego Bertolini

diegobertolini@utfpr.edu.br

Aula 002

- **Aula Anterior:**
 - Introdução ;
- **Aula de Hoje:**
 - Aprendizagem de Máquina

Objetivo

O que vocês devem saber ao final da aula:

Introdução a Aprendizagem de Máquina e Tipos de Aprendizagens.

Introdução

Computadores realmente são capazes de aprender?

Infelizmente ainda não sabemos exatamente como fazer computadores aprender de uma maneira similar a maneira como os **humanos aprendem**.

Entretanto, existem **algoritmos** que são eficientes em certos tipos de tarefas de aprendizagem.

O que é Aprendizagem de Máquina?

Aprender significa “**mudar para fazer melhor**” (de acordo com um dado critério) quando uma situação similar acontecer.

Aprendizagem, **não é memorizar**. Qualquer computador pode memorizar, a dificuldade está em **generalizar** um comportamento para uma nova situação.

Formas de Aprendizado

Aprendizado Supervisionado

Aprendizado Não Supervisionado

Aprendizado Por Reforço

Aprendizado Supervisionado

Observa-se alguns pares de **exemplos de entrada e saída**, de forma a aprender uma **função que mapeia a entrada para a saída**.

Damos ao sistema a “**resposta correta**” durante o processo de treinamento.

É eficiente pois o sistema pode trabalhar diretamente com informações corretas.

“Útil para classificação, regressão, estimação de probabilidade condicional (qual é a probabilidade de um cliente com um determinado perfil comprar um determinado produto?)

Aprendizado Supervisionado

Exemplo:

Considerando um agente treinando para ser se tornar um motorista de táxi. Toda vez que o instrutor gritar "freio!" o agente pode aprender uma condição de quando ele deve frear.

A entrada é formada pelos dados percebidos pelo agente através de sensores. A saída é dada pelo instrutor que diz quando se deve frear, virar a direita, virar a esquerda, etc.

Aprendizado Não Supervisionado

O agente **reconhece padrões nos dados de entrada**, mesmo sem **nenhum feedback de saída**.

Por exemplo, um agente aprendendo a dirigir pode gradualmente desenvolver um conceito de dias de bom tráfego e dias de tráfego congestionado mesmo sem nunca ter recebido exemplos rotulados por um professor.

Aprendizado Por Reforço

O agente recebe uma série de reforços, **recompensas ou punições**.

Por exemplo, a falta de uma gorjeta no final do percurso da ao agente taxista uma indicação de que ele fez algo errado.

Cabe ao agente reconhecer qual das ações antes do reforço foram as maiores responsáveis por isso.

Não damos a “resposta correta” para o sistema. O sistema faz uma hipótese e determina se essa hipótese foi boa ou ruim.

Fases da Aprendizagem

Treinamento

Apresenta-se exemplos ao sistema.

O sistema “aprende” a partir dos **exemplos**.

O sistema modifica gradualmente os seus parâmetros para que a saída se aproxime da saída desejada.

Validação

Novos exemplos jamais visto são apresentados ao sistema.

O sistema deve generalizar e reconhecê-los.


Exemplos de Treinamento (Aprendizado Supervisionado)

Atributos							Classe
Exemplo	Atrib ₁	Atrib ₂	Atrib ₃	Atrib ₄	Atrib ₅	Atrib ₆	
X₁	0.24829	0.49713	0.00692	-0.020360	0.429731	-0.2935	1
X₂	0.24816	0.49729	0.00672	0.0065762	0.431444	-0.29384	1
X₃	0.24884	0.49924	0.01047	-0.002901	0.423145	-0.28956	3
X₄	0.24802	0.50013	0.01172	0.001992	0.422416	-0.29092	2
X₅	0.24775	0.49343	0.01729	-0.014341	0.420937	-0.29244	2

Classificação de Exemplos Desconhecidos

Atributos							
Exemplo	Atrib ₁	Atrib ₂	Atrib ₃	Atrib ₄	Atrib ₅	Atrib ₆	Classe
X ₁	0.22829	0.48713	0.00592	-0.010360	0.419731	-0.2845	?
X ₂	0.21816	0.48729	0.00572	0.0045762	0.421444	-0.28484	?
X ₃	0.23884	0.49824	0.01447	-0.003901	0.433145	-0.24956	?
X ₄	0.23002	0.49013	0.02172	0.002992	0.412416	-0.28092	?
X ₅	0.24575	0.49243	0.01029	-0.015341	0.430937	-0.28244	?

Espaço de Características



Tipos de Problemas

Classificação:

Responde se uma determinada “entrada” pertence a uma certa classe.

Dada a imagem de uma face: de quem é esta face (dentre um número finito).

Regressão:

Faz uma predição a partir de exemplos.

Predizer o valor da bolsa amanhã, dados os valores de dias e meses anteriores.


Estimação de Densidade:

Estima quais são as N categorias presente nos dados.

Aprendizado Supervisionado

Dado uma quantidade finita de dados para o treinamento, temos que derivar uma função h que se aproxime da verdadeira função $f(\mathbf{x})$ (a qual gerou os dados e é desconhecida).


Existe um número infinito de funções h .



Aprendizado Supervisionado

Dado uma quantidade finita de dados para o treinamento, temos que derivar uma função h que se aproxime da verdadeira função $f(\mathbf{x})$ (a qual gerou os dados e é desconhecida).


Existe um número infinito de funções h .



Aprendizado Supervisionado

Dado uma quantidade finita de dados para o treinamento, temos que derivar uma função h que se aproxime da verdadeira função $f(x)$ (a qual gerou os dados e é desconhecida).


Existe um número infinito de funções h .



Aprendizado Supervisionado

Dado uma quantidade finita de dados para o treinamento, temos que derivar uma função h que se aproxime da verdadeira função $f(x)$ (a qual gerou os dados e é desconhecida).

Existe um número infinito de funções h .



Generalizar é Difícil

Não queremos aprender por memorização

Boa resposta sobre os exemplos de treinamento somente.

Fácil para um computador.

Difícil para os humanos.

Aprender visando generalizar


Mais interessante.

Fundamentalmente mais difícil: diversas maneiras de generalizar.

Devemos extrair a essência, a estrutura dos dados e não somente aprender a boa resposta para alguns casos.


Exemplo

Função-alvo f (melhor resposta possível).




Exemplo - Overfitting

Erro baixo sobre os exemplos de aprendizagem.
Mais elevado para os de teste.




Exemplo - Underfitting

Escolhemos um modelo muito simples (linear): erro elevado na aprendizagem.



Exemplo – Um Bom Modelo

O modelo é suficientemente flexível para capturar a forma curva da função f mais não é suficiente para ser exatamente igual a função f .



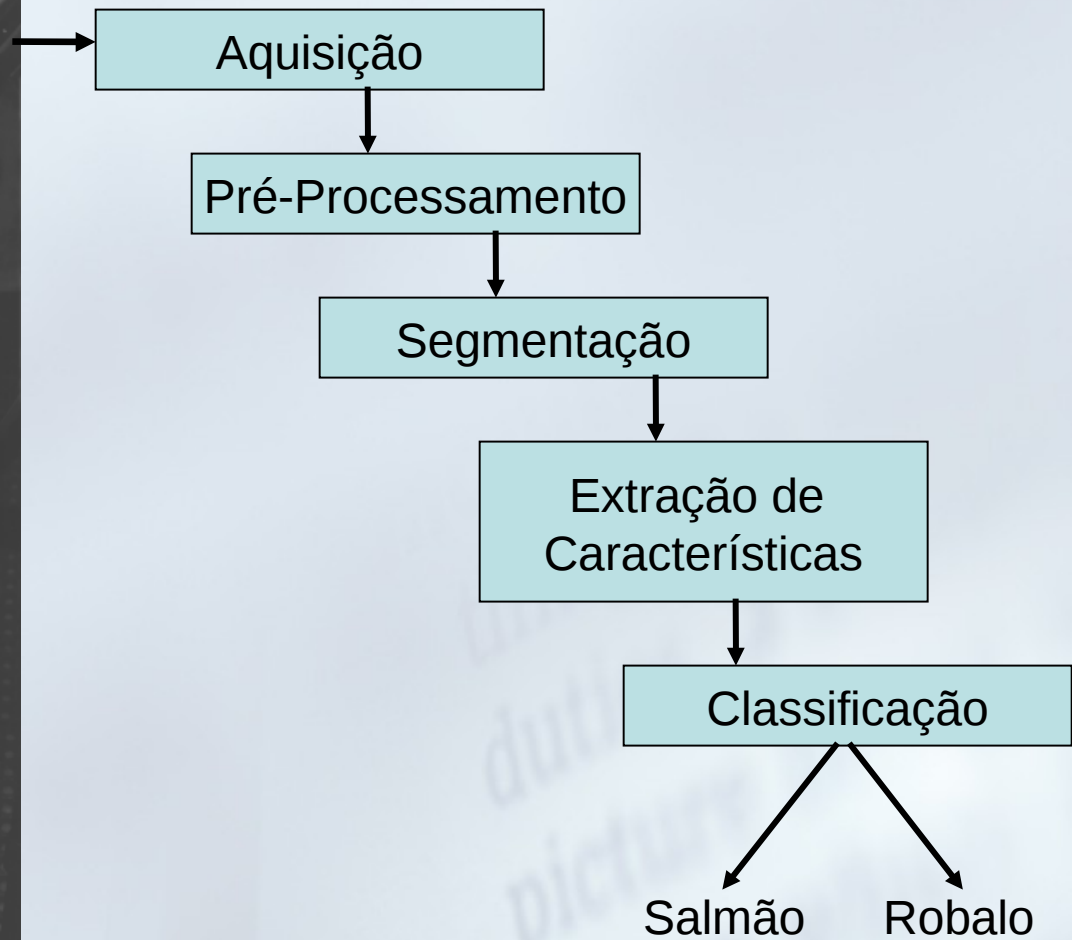
Teoria de Aprendizado Computacional

Como sabemos se a hipótese h está próxima da função-alvo f , se não conhecemos o que é f ?

Este é um aspecto de uma questão mais abrangente: como saber se um algoritmo de aprendizado produziu uma teoria que preverá corretamente o futuro?

Qualquer hipótese que é consistente com um conjunto suficientemente grande de exemplos é pouco provável de estar seriamente errada.

Exemplo



Sistema Clássico – Pré-processamento

Simplificação do sinal capturado pela câmera.

Ex: Eliminação de alguns ruídos.

Processamento digital de imagens.

Tornar os processos subsequentes mais simples e rápidos.

Sistema Clássico – Segmentação

Isolar os objetos de interesse na imagem.

No nosso exemplo, encontrar o que é peixe e o que não é peixe.

Processamento Digital de Imagens

- Filtros, morfologia matemática, etc...



Sistema Clássico – Segmentação

Segundo nível de
segmentação.

Encontrar e segmentar
os objetos de interesse
detectados na primeira
fase da segmentação.



Sistema Clássico – Extração de Características

A imagem do objeto de interesse é enviada para o módulo de extração de características.

Reduzir a complexidade através da extração de certas “características” ou “propriedades”.

Sistema Clássico – Classificação

As características (valores) são passadas para o classificador, o qual toma uma decisão

No nosso exemplo: Salmão ou Robalo.

Mas que tipo de características devemos usar?

Conceitos básicos de classificação

Suponha que alguém nos diga que:

Robalos *geralmente* são maiores que salmões.

Isso nos dá uma direção para modelar nosso problema, ou seja,

Se o peixe ultrapassa um tamanho t , então ele é um robalo, caso contrário, é um salmão.

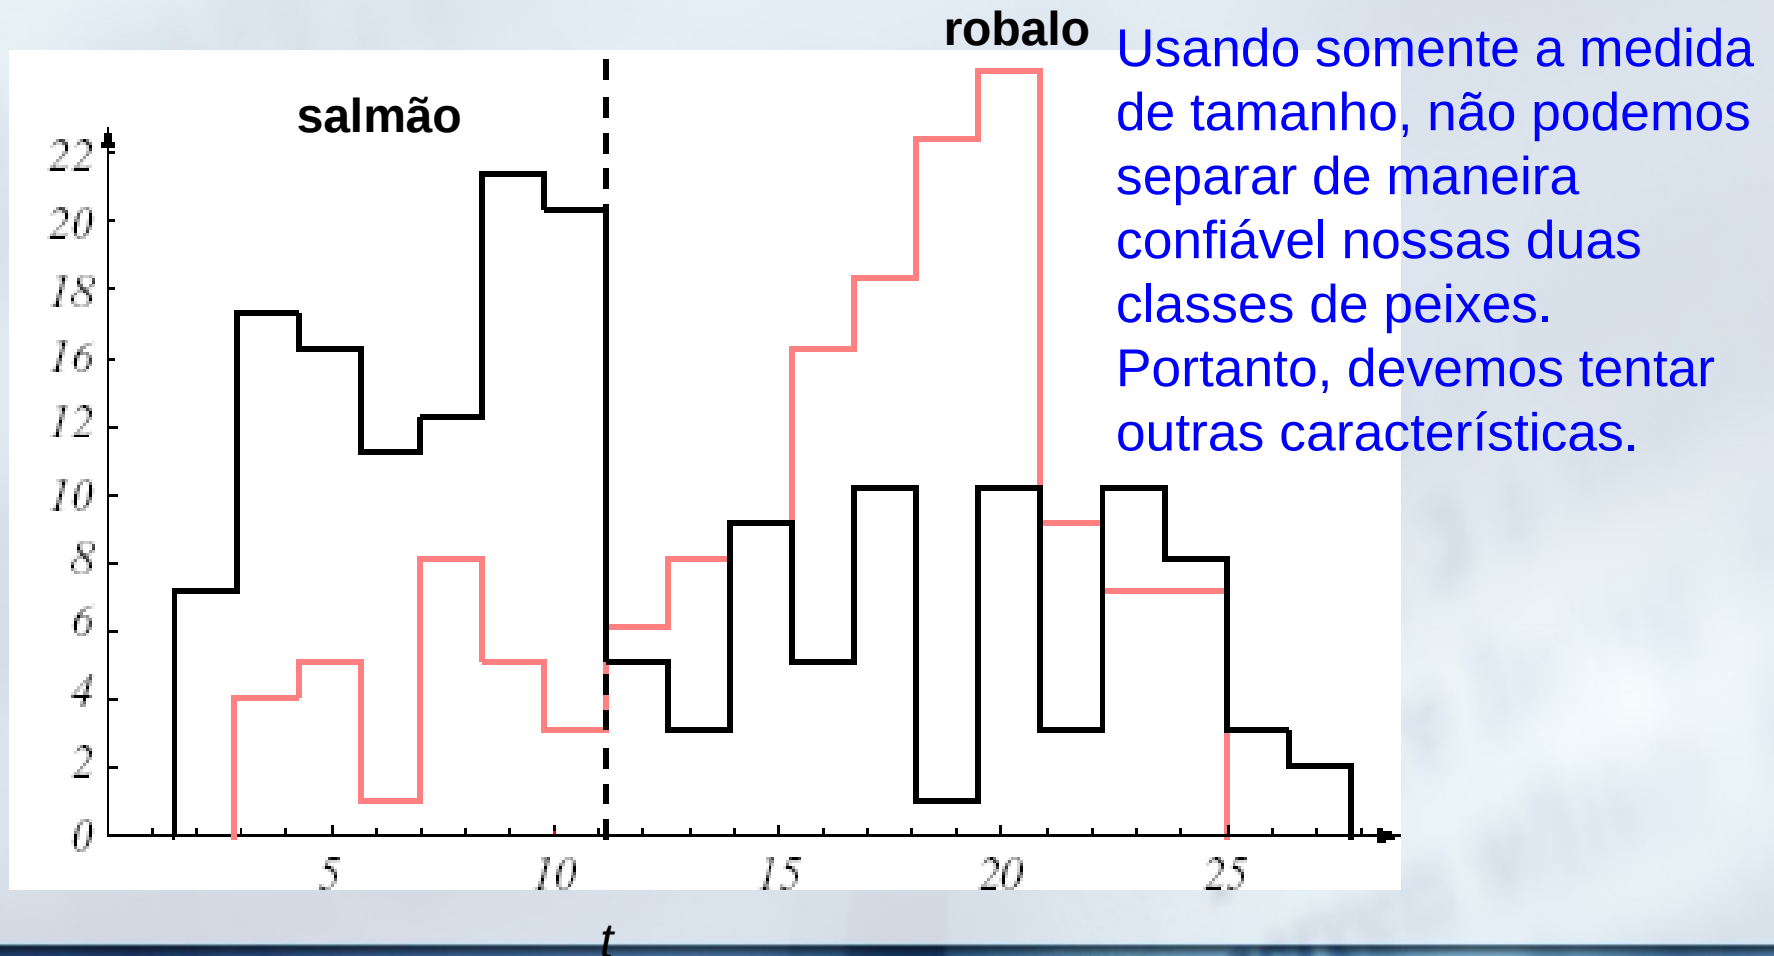
Mas como determinar t ??

Conceitos básicos de classificação

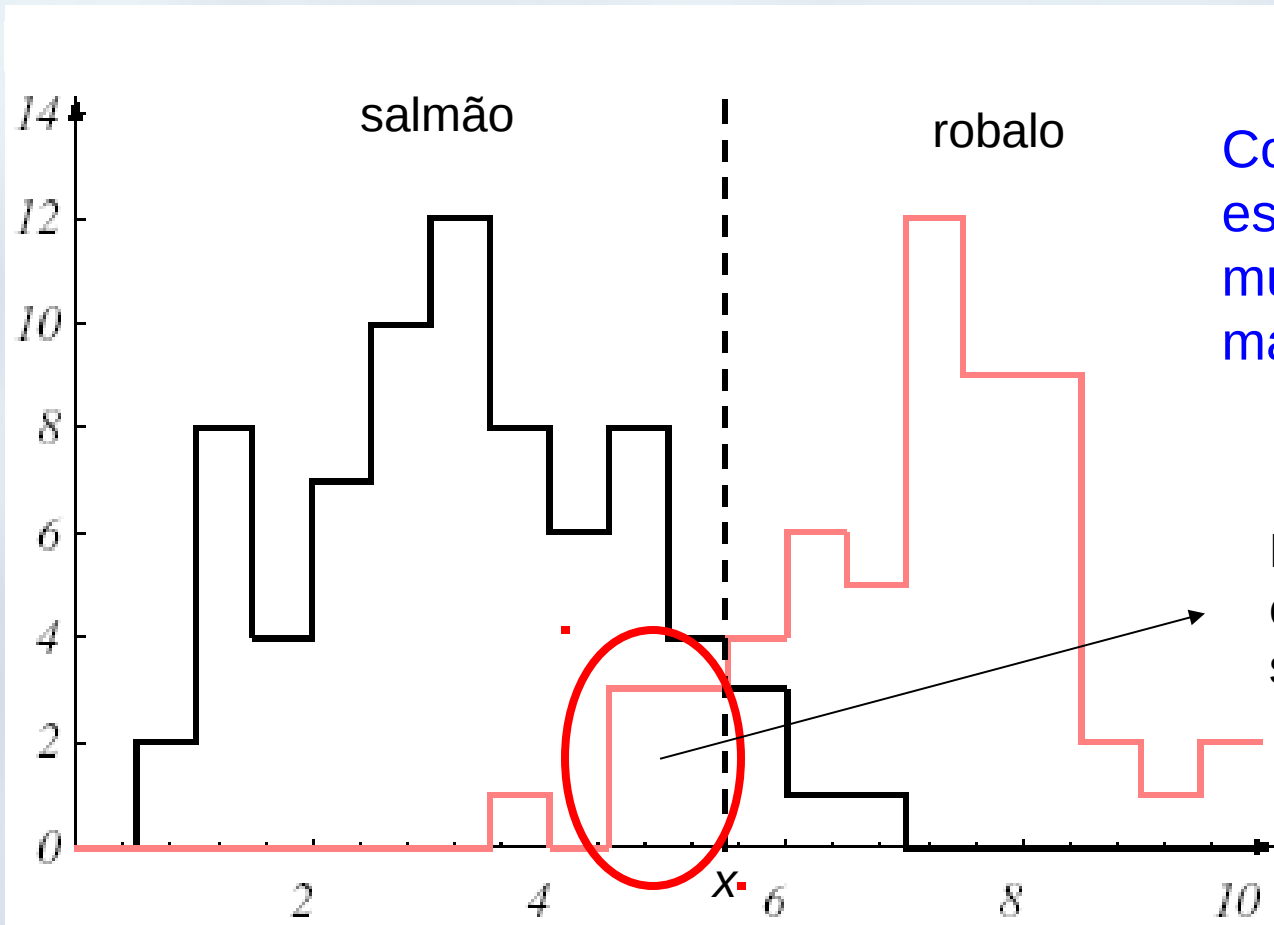
Podemos selecionar alguns exemplares (**base de treinamento**) de peixe e verificar seus tamanhos.

Suponha que após analisarmos nossa base de treinamento, tenhamos os seguintes histogramas

Conceitos básicos de classificação




Conceitos básicos de classificação



Como podemos notar, essa característica é muito mais confiável, mas não é perfeita.

Robalos que serão classificados como salmão.



Noção de
CUSTO


Outra característica: Medida de Claridade (coloração)

Conceitos básicos de classificação

Suponha que os clientes da nossa indústria aceitem um pedaço de salmão embalado junto com robalo, mas o contrário é inaceitável.

Devemos então alterar nossa fronteira para que isso não aconteça.

Conceitos básicos de classificação



Custo maior, uma vez que mais salmões serão classificados como robalos

Erro Bayesiano

Conceitos básicos de classificação

Isso sugere que existe um **custo** associado com a nossa decisão.

Nossa tarefa consiste em encontrar uma regra de decisão que minimize o custo.

Isso é o papel central da **Teoria da Decisão**.

Também pode ser visto como um problema de otimização.

Conceitos básicos de classificação

Como minimizar o custo?

Buscar outras características.


- Suponha que a claridade seja a melhor.

Podemos utilizar duas características ao mesmo tempo.

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

Vetor de características bi-dimensional.

Conceitos básicos de classificação



Nossa base de treinamento em um gráfico de dispersão

Conceitos básicos de classificação

Nosso problema consiste em encontrar a **fronteira de decisão** que minimize o custo.


Modelo mais simples:

Separação linear ;

Algoritmos tradicionais:

- Perceptron, Funções Discriminantes Lineares.

Conceitos básicos de classificação



Conceitos básicos de classificação

Essa regra fornece uma boa fronteira de decisão, entretanto pode ser melhorada.

Adicionar mais características, como por exemplo, dimensões do peixe, posição relativa dos olhos, etc..., poderiam ajudar.

Quanto mais características, mais base de treinamento será necessária.

– Maldição da dimensionalidade.


Conceitos básicos de classificação

Suponha que não dispomos de mais características.

Solução:

Construir um modelo mais complexo do que um modelo linear.

Conceitos básicos de classificação



Conceitos básicos de classificação

Apesar de complexo, esse modelo é pior do que o modelo linear.

A principal característica de um modelo deve ser a sua capacidade de **generalizar**.


Modelos muito complexos geralmente não generalizam bem, pois decoram a base de treinamento (**over-fitting**).

Conceitos básicos de classificação

Por outro lado, modelos muito simples tendem a generalizar demais (**under-fitting**).

Na aprendizagem de máquina, veremos técnicas para evitar *over-* e *under-fitting*, ou seja, construir fronteiras de decisão nem tão simples e nem tão complexas.

Conceitos básicos de classificação



Bibliografia e Materiais.

Estes slides foram adaptados do Livro:

Russell, S. and Norvig, P. Artificial Intelligence: a Modern Approach, 2nd Edition, Prentice-Hall, 2003. Capítulo 18: Learning from Examples;

Adaptado das Aulas do Professor: Ederley – PUC-RIO ;

