

Inteligência Artificial

BCC35G

Diego Bertolini

diegobertolini@utfpr.edu.br

<http://www.inf.ufpr.br/diegob/>

Aula 010

- **Aula Anterior:**
 - **Aprendizagem Supervisionada – Decision Trees**
- **Aula de Hoje:**
 - **Aprendizagem Supervisionada – Support Vector Machine**

Objetivo

O que vocês devem saber ao final da aula:

Conceitos básicos do SVM;

Formas de Aprendizado

Aprendizado Supervisionado

- K-Nearest Neighbor (KNN). (ok)
- Árvores de Decisão. (ok)
- **Support Vector Machines (SVM).**
- Redes Neurais.

Aprendizado Não-Supervisionado

- K-means (ok)

Aprendizado Por Reforço

Aprendizado Supervisionado

- Observa-se alguns pares de **exemplos de entrada e saída**, de forma a aprender uma **função que mapeia a entrada para a saída**.
- Damos ao sistema a **resposta correta** durante o processo de treinamento.
- É eficiente pois o sistema pode trabalhar diretamente com informações corretas.

Support Vector Machine

- Proposto em 1995 pelo russo Vladimir Vapnik.
- Consiste em um método de aprendizado que tenta encontrar a maior margem para separar diferentes classes de dados.
- Pertence à classe de algoritmos de aprendizado supervisionado.
- A essência do SVM é a construção de um hiperplano ótimo, de modo que ele possa separar diferentes classes de dados com a maior margem possível.

Support Vector Machine

- Como separar essas duas classes?




Support Vector Machine

- Como separar essas duas classes?
 - Existem diversas retas que podem ser traçadas para separar os dados.
- Qual delas é a melhor opção?




Support Vector Machine

- Como separar essas duas classes?
 - Existem diversas retas que podem ser traçadas para separar os dados.
- Qual delas é a melhor opção?
 - **Hiperplano ótimo!**



Vetores de Suporte


- Servem para definir qual será o hiperplano.
- São encontrados durante a fase de treinamento.
- Os vetores de suporte são os exemplos de treinamento realmente importantes. Os outros exemplos podem ser ignorados.




Support Vector Machine

- Hiperplano:


- Espaço 1D = Ponto



Espaço 2D = Reta




- Espaço 3D = Plano



Support Vector Machine

- A aplicação de um método puramente linear para classificar um conjunto de dados pode sofrer com **dois problemas** bastante comuns:
 - Outliers
 - Exemplos rotulados erroneamente
- Mesmo assim o SVM ainda assim pode ser aplicado através do uso do parâmetro C (**soft margin** - variáveis de folga)

Soft Margin



Support Vector Machine

- Em alguns problemas não é possível separar as classes linearmente mesmo utilizando a margem de folga.
- Na realidade, a grande maioria dos problemas reais não são separáveis linearmente.
- O que fazer?

Problemas Não Lineares

- Os problemas reais geralmente não são linearmente separáveis.
- Para utilizar máquinas lineares, é necessário que os dados sejam projetados em um dimensão onde os mesmos sejam linearmente separáveis.



Kernel Trick


- A função que projeta o espaço de entrada no espaço de características é conhecida com *Kernel* ;
- Baseado no teorema de Cover
 - Dados no espaço de entrada são transformados para o espaço de características, onde são linearmente separáveis.

SVM Não-Linear

- O que fazer quando os dados não são linearmente separáveis?




- A abordagem utilizada pelo SVM para resolver esse tipo de problema consiste em mapear os dados para um espaço de dimensão maior:




SVM Não-Linear

- O espaço de atributos original pode ser mapeado em um espaço de atributos de dimensão maior onde o conjunto de treinamento é linearmente separável:



Exemplo

$$\begin{aligned}\phi : \quad \mathbb{R}^2 &\longrightarrow \mathbb{R}^3 \\ (x_1, x_2) &\longmapsto (z_1, z_2, z_3) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)\end{aligned}$$




SVM Não-Linear Exemplo

- Considerando o seguinte conjunto de exemplos de treinamento que não são linearmente separáveis:



- Elevando para uma dimensão linearmente separável ($\mathbb{R}^1 \rightarrow \mathbb{R}^2$):




- Kernel:** $\varphi(x) = (x, x^2)$

SVM Não-Linear Exemplo



- A mesma metodologia pode ser aplicada em um espaço 2D de características ($\mathbb{R}^2 \rightarrow \mathbb{R}^3$).
- A única diferença é a necessidade de uma nova função de kernel. Um exemplo de função de kernel aplicável nesse caso seria:

$$\varphi(x_1, x_2) \rightarrow (z_1, z_2, z_3) = (x_1^2, \sqrt{2x_1x_2}, x_2^2)$$



Funções de Kernel

Kernel	Função $\phi(x_i, x_j)$
Polinomial	$(\delta(x_i \cdot x_j) + k)^d$
Gaussiano	$\exp(-\sigma \ x_i - x_j\ ^2)$
Sigmoidal	$\tanh(\delta(x_i \cdot x_j) + k)$



Support Vector Machine

- O SVM foi originalmente concebido para lidar com **classificações binárias**.
- Entretanto, a maior parte dos problemas reais requerem **múltiplas classes**.
- Para se utilizar uma SVM para classificar múltiplas classes é necessário transformar o problema multi-classe em vários problemas de classes binárias
 - Um contra todos.
 - Pairwise.

Aplicação

- Antes de aplicar uma SVM para classificar um conjunto de dados é necessário responder algumas questões:
 - Quais funções de kernel utilizar?
 - Qual o valor do parâmetro C (Soft Margin)?
- Validações cruzadas (cross-validations).

Vantagens e Desvantagens

- **Vantagens:**

- Consegue lidar bem com grandes conjuntos de exemplos.
- Trata bem dados de alta dimensão.
- O processo de classificação é rápido.

- **Desvantagens:**

- É necessário definir um bom Kernel.
- O tempo de treinamento pode ser bem longo dependendo do número de exemplos e dimensionalidade dos dados.

Aplicações

- Categorização de texto
 - Filtragem de email
 - Web-searching
 - Classificação/Indexação de documento
 - GED.

Aplicações

- **Imagens**
 - Indexação de imagens
 - Aplicações médicas
 - Recuperação de imagens (Image Retrieval)

Aplicações

- Reconhecimento da escrita.
 - Geralmente com resultados melhores que outros tipos de classificadores.
- Bio-Informática
 - Categorização automática de genes em DNA.
 - Seqüências de aminoácidos.
 - Classificação de proteínas.

Bibliografia e Materiais.

Estes slides foram adaptados do Livro:

Adaptado das Aulas do Professor Ederley – PUC-RIO

Livro: Duda, R., Hart, P., Stork, D., **Pattern Classification**, John Wiley & Sons, 2000

